



UNIVERSITAT
POLITÈCNICA
DE VALÈNCIA



Escola Tècnica
Superior d'Enginyeria
Informàtica

Escuela Técnica Superior de Ingeniería Informática
Universidad Politécnica de Valencia

Métricas del gradiente como indicadores de la eficiencia del entrenamiento en redes neuronales

TRABAJO FIN DE GRADO

Grado en Ciencia de Datos

Autor: Laiqian Ji

Tutor: Javier Jorge Cano

Curso 2025-2026

Agradecimientos

Resum

????

Paraules clau: alineació de gradients, variància del gradient, parada primerenca, descens per gradient estocàstic, xarxes neuronals

Resumen

????

Palabras clave: alineación de gradientes, varianza del gradiente, parada temprana, descenso por gradiente estocástico, redes neuronales

Abstract

????

Key words: gradient alignment, gradient variance, early stopping, stochastic gradient descent, neural networks

Índice general

Índice general	V
Índice de figuras	VII
Índice de tablas	VII
1 Introducción	1
1.1 Motivación	1
1.2 Objetivos	2
1.3 Alcance y limitaciones	3
1.4 Estructura de la memoria	3
2 Estado del arte	5
2.1 Predicción temprana de la eficiencia del entrenamiento	5
2.2 Familia de alineación o coherencia direccional	6
2.3 Familia de variabilidad estocástica	7
2.4 Predictores de referencia sin instrumentar el gradiente	8
2.5 Posicionamiento de este trabajo	8
3 Fundamentos teóricos	11
3.1 Descenso por gradiente estocástico	11
3.2 Geometría del gradiente	12
3.3 Métricas de alineación	12
3.4 Métricas de variabilidad	14
3.5 Indicadores de eficiencia del entrenamiento	15
4 Metodología y diseño experimental	17
4.1 Hipótesis	17
4.2 Variables	17
4.2.1 Dependientes: eficiencia del entrenamiento	17
4.2.2 Independientes: métricas tempranas	17
4.3 Ventana temporal	17
4.4 Setup de entrenamiento	17
4.5 Matriz de experimentos	18
4.6 Protocolo de evaluación	18
4.7 Protocolo de análisis	18
4.8 Amenazas a la validez	18
5 Implementación	19
5.1 Arquitectura del pipeline	19
5.2 Cálculo de las métricas	19
5.3 Reproducibilidad	19
5.4 Ejecución y reanudación en cluster	19
5.5 Pilot de calibración	19
6 Resultados	21
6.1 Calibración del pilot	21
6.2 Correlaciones por condición	21
6.3 Análisis agregado y barrido temporal	21

6.4	Valor incremental sobre el baseline	21
6.5	Qué familia predice mejor	21
6.6	Robustez cross-optimizador	21
6.7	Frente de Pareto: potencia predictiva vs coste	21
6.8	Coherencia con el mecanismo declarado	21
7	Conclusiones	23
7.1	Cumplimiento de objetivos	23
7.2	Aportaciones	23
7.3	Limitaciones	23
7.4	Trabajo futuro	23
	Bibliografía	25
	A Objetivos de Desarrollo Sostenible	27
	Apéndices	
B	Configuración del sistema y reproducibilidad	29
B.1	Entorno software	29
B.2	Hardware y ejecución	29
B.3	Reproducibilidad determinista	29

Índice de figuras

Índice de tablas

2.1	Las métricas tempranas revisadas, situadas en ejes comunes. El coste es relativo al de un paso de entrenamiento. La señal indica el sentido que cada trabajo asocia con un entrenamiento más eficiente o una mejor generalización.	9
2.2	Cobertura de este trabajo frente a trabajos representativos del estado del arte, en los ejes que definen la aportación.	9
4.1	Conjuntos de datos y particiones. El conjunto de validación se obtiene del entrenamiento oficial por muestreo estratificado por clase con semilla fija; el de prueba es el oficial. En Tiny-ImageNet el conjunto de validación público hace de prueba, porque las etiquetas del de prueba oficial no son públicas; por eso el total usable es de 110.000 ejemplos y no de 120.000. . .	17
4.2	Exactitud de test de referencia por arquitectura en el <i>régimen comparable</i> (desde cero, sin aumento de datos, resolución nativa), que es el de este estudio. Son bandas esperadas, no objetivos: las fuentes suelen entrenar más tiempo o con redes algo mayores, de modo que acotan por arriba. Las celdas con † no tienen baseline publicado en este régimen (CNN simple y ResNet-18 desde cero, sin aumento, a 64×64 nativo en Tiny-ImageNet); son estimaciones y un punto de datos novedoso del estudio.	18

Listado de abreviaturas, siglas y acrónimos

SGD Descenso por gradiente estocástico (*stochastic gradient descent*).

CAPÍTULO 1

Introducción

Este capítulo presenta el problema que motiva el trabajo y enmarca lo que sigue. La Sección 1.1 expone por qué interesa predecir la eficiencia de un entrenamiento desde sus primeras épocas y dónde está el hueco que esta memoria pretende cubrir. La Sección 1.2 formula la pregunta de investigación y los objetivos que de ella se derivan. La Sección 1.3 delimita el estudio, separando lo que entra de lo que queda fuera de forma deliberada. La Sección 1.4 cierra el capítulo con un recorrido por el resto de la memoria.

1.1 Motivación

El entrenamiento de redes neuronales profundas es uno de los procesos más costosos del aprendizaje automático actual. Cada vez que se elige una arquitectura, un optimizador o un conjunto de hiperparámetros, la forma habitual de comprobar si la elección es buena consiste en lanzar el entrenamiento completo y medir el resultado. Ese proceder es caro en tiempo, en energía y en dinero, y se repite muchas veces, porque el espacio de configuraciones posibles es enorme y rara vez se sabe de antemano cuál funcionará mejor.

Buena parte de ese coste se gasta en entrenamientos que podrían descartarse pronto. Muchas configuraciones revelan en sus primeras épocas que van a converger despacio o a estancarse, y sin embargo se las deja correr hasta el final solo para confirmar lo que ya se intuía. Si fuera posible anticipar, a partir de una fracción inicial del entrenamiento, si una configuración va a ser eficiente, se podría decidir antes y reservar el cómputo para las candidatas prometedoras. La cuestión es qué señal temprana contiene esa información.

Precisamente, si analizamos las diferentes partes que componen el proceso de entrenamiento de una red neural, el gradiente surge como la señal más natural para observar el progreso del aprendizaje. Es la única información que el optimizador utiliza para avanzar en cada paso, de modo que su comportamiento en las primeras etapas refleja directamente cómo está aprendiendo la red. Dos aspectos del gradiente han recibido atención de forma independiente. El primero es su variabilidad estocástica, es decir, cuánto cambia el gradiente de un minibatch a otro: si la dispersión entre minibatches es grande, el optimizador recibe estimaciones ruidosas y avanza con dificultad. El segundo es su alineación direccional, esto es, en qué medida los gradientes de ejemplos distintos apuntan hacia el mismo sitio: cuando ejemplos distintos empujan en la misma dirección, el paso de descenso beneficia a muchos a la vez y el aprendizaje progresa de forma coherente.

En los últimos años se han propuesto varias métricas para cuantificar estos dos aspectos. El problema es que cada una se ha presentado por separado, en su propio trabajo, con su propio conjunto de datos y su propia arquitectura, y casi siempre con un objetivo

distinto: explicar por qué una red generaliza, elegir el tamaño de batch o decidir cuándo detener el entrenamiento. Falta una comparación directa entre familias sobre un mismo banco de pruebas; falta saber cuán temprano basta medir para que la predicción ya sea fiable; y falta comprobar si la relación se mantiene al cambiar de problema, de arquitectura y de optimizador. Sobre todo, falta una comprobación que rara vez se hace de forma explícita: si estas métricas, que obligan a instrumentar el gradiente y por tanto tienen un coste, aportan algo por encima de lo que la propia curva de pérdida ya ofrece sin coste alguno.

Este trabajo aborda ese hueco con un estudio correlacional sistemático. Se entrena una rejilla amplia de configuraciones de visión por computador, se miden en todas ellas las dos familias de métricas a lo largo de distintas fracciones tempranas del entrenamiento, y se cuantifica en qué medida cada métrica predice indicadores de eficiencia del entrenamiento completo. El criterio de éxito no es solo que una métrica correlacione con la eficiencia, sino que lo haga mejor que la señal gratuita de la curva de pérdida y a un coste razonable. Un resultado negativo sólidamente establecido, esto es, demostrar que el gradiente no aporta nada que la pérdida no contenga ya, sería también una contribución útil, porque ahorraría a otros el coste de instrumentarlo.

1.2 Objetivos

La pregunta de investigación que vertebra la memoria es la siguiente:

¿Pueden las métricas de variabilidad y alineación de gradientes, medidas en la fase inicial del entrenamiento, predecir la eficiencia del entrenamiento completo?

De esta pregunta general se desprenden cuatro sub-preguntas. La primera es de viabilidad: qué métrica es estable y computacionalmente asumible. La segunda es de objetivo: si lo que se predice es la velocidad de convergencia o el rendimiento final. La tercera es de robustez: si la relación se mantiene al variar la tasa de aprendizaje y el optimizador. La cuarta, y la más exigente, es de valor: si la métrica aporta información que la curva de pérdida no contenga ya sin coste.

El objetivo general del trabajo es cuantificar en qué medida las métricas tempranas de gradiente predicen la eficiencia del entrenamiento completo en tareas de clasificación de imágenes, e identificar cuáles ofrecen la mejor capacidad predictiva por unidad de coste. Este objetivo general se concreta en seis objetivos específicos:

1. **Existencia.** Determinar si al menos una métrica temprana de gradiente se relaciona de forma apreciable con la eficiencia en la mayoría de las condiciones estudiadas.
2. **Valor incremental.** Comprobar si alguna métrica conserva poder predictivo después de descontar lo que la curva de pérdida ya predice sin coste. Es el contraste decisivo del trabajo.
3. **Comparación de familias.** Establecer cuál de las dos familias, la de alineación o la de variabilidad, es sistemáticamente más predictiva o más robusta.
4. **Suficiencia temprana.** Determinar cuán temprano basta medir para que la predicción no mejore de forma apreciable al esperar más.
5. **Robustez entre optimizadores.** Evaluar si el sentido de la relación se preserva al cambiar de descenso por gradiente estocástico (SGD) a Adam.

6. **Mecanismo.** Verificar si el sentido de cada relación observada coincide con el que predice el trabajo del que procede cada métrica.

Estos seis objetivos se formalizan en el Capítulo 4 como otras tantas hipótesis contrastables, cada una con un criterio falsable preestablecido. El Capítulo 7 retoma la lista para examinar, uno a uno, en qué medida se han alcanzado.

1.3 Alcance y limitaciones

El trabajo es un estudio *correlacional*. Su finalidad es medir la asociación entre las métricas tempranas y la eficiencia, no intervenir en el entrenamiento a partir de esa señal. La componente de intervención, por ejemplo detener el entrenamiento de forma anticipada o ajustar la tasa de aprendizaje en función de la alineación medida, queda fuera del alcance y se recoge como línea de trabajo futuro en el Capítulo 7. Como en todo estudio correlacional, las relaciones que se encuentren no deben interpretarse como relaciones causales.

El dominio es la visión por computador, en concreto la clasificación de imágenes. El estudio abarca cuatro conjuntos de datos de dificultad creciente, tres familias de arquitectura (una totalmente conectada, una red convolucional simple y una ResNet-18) y dos optimizadores (SGD y Adam). La combinación da lugar a una rejilla de configuraciones que, con varias tasas de aprendizaje y varias semillas por configuración, supera los novecientos entrenamientos. El detalle de esta rejilla se expone en el Capítulo 4.

Quedan fuera del alcance, de forma deliberada, los dominios distintos de la visión, las arquitecturas de tipo transformador y los conjuntos de datos a gran escala. En particular, el conjunto ImageNet completo se sustituye por una versión reducida, Tiny-ImageNet, por restricciones de disco y de cómputo; esta sustitución y sus consecuencias se declaran abiertamente en el Capítulo 4. El entrenamiento se realiza sin aumento de datos, porque el estudio es sensible al determinismo del proceso y el aumento de datos introduciría una fuente de variación adicional.

1.4 Estructura de la memoria

El resto de la memoria se organiza como sigue. El Capítulo 2 revisa de forma crítica la literatura, ordenándola en torno a las dos familias de métricas y a los predictores de eficiencia que sirven de referencia, y termina situando la aportación de este trabajo frente a lo existente. El Capítulo 3 fija las definiciones formales que el estado del arte deja enunciadas, desde el descenso por gradiente estocástico hasta cada una de las métricas y los indicadores de eficiencia. El Capítulo 4 presenta el diseño experimental: las hipótesis con sus criterios falsables, las variables, la ventana temporal, la rejilla de entrenamientos, el protocolo de evaluación y el de análisis, y las amenazas a la validez que el diseño debe neutralizar. El Capítulo 5 describe el desarrollo del software que hace posible el estudio. El Capítulo 6 reúne los resultados de los experimentos. El Capítulo 7 interpreta esos resultados, revisa el cumplimiento de los objetivos y señala las líneas de continuación. Cierran la memoria los anexos, que recogen la reflexión sobre los Objetivos de Desarrollo Sostenible y los detalles de configuración necesarios para reproducir el estudio.

CAPÍTULO 2

Estado del arte

Este capítulo revisa la literatura que sostiene el trabajo. No pretende ser exhaustivo, sino selectivo y crítico: de cada propuesta interesa la idea central, lo que sus autores encontraron y, sobre todo, qué deja sin resolver. Las definiciones formales de cada métrica se posponen al Capítulo 3; aquí se manejan en su versión conceptual para no romper el hilo argumental. La Sección 2.1 sitúa el problema general de predecir el resultado de un entrenamiento desde sus primeras épocas, un problema que la búsqueda de arquitecturas neuronales lleva años abordando. La Sección 2.2 revisa la familia de métricas de alineación o coherencia direccional, y la Sección 2.3 la de variabilidad estocástica. La Sección 2.4 introduce los predictores que sirven de referencia y que cualquier métrica de gradiente debe superar para justificar su coste. La Sección 2.5 cierra el capítulo situando la aportación de este trabajo frente a lo revisado.

2.1 Predicción temprana de la eficiencia del entrenamiento

La idea de anticipar el resultado de un entrenamiento sin llegar a completarlo no es nueva. El campo que más la ha trabajado es la búsqueda de arquitecturas neuronales (NAS, por sus siglas en inglés), donde el coste de entrenar a fondo cada arquitectura candidata es prohibitivo: evaluar un espacio de búsqueda completo puede requerir miles de horas de procesador gráfico. La respuesta natural ha sido estimar el rendimiento final de cada candidata a partir de unas pocas épocas de entrenamiento, de modo que el ranking aproximado baste para descartar la mayoría y reservar el cómputo para las prometedoras.

El representante más directo de esta línea es el estimador de velocidad de entrenamiento (TSE), propuesto por Ru et al. [1]. La observación que lo sustenta es que las arquitecturas que acabarán generalizando mejor tienden a entrenar más deprisa desde el principio, de modo que una suma de las pérdidas de entrenamiento tempranas, sin tocar el conjunto de test ni un conjunto de validación, ya ordena bien a las candidatas. Los autores muestran que su estimador correlaciona fuertemente, en términos de Spearman y Kendall, con el ranking real de test, y que lo hace de forma más estable que los llamados proxies de coste cero, que se evalúan en la inicialización sin entrenar nada. Su principal virtud es el coste: la pérdida de entrenamiento ya se calcula en cada paso, así que el estimador es prácticamente gratuito.

Precisamente esa virtud es la que convierte a TSE en el rival a batir, no en un colaborador. Si la curva de pérdida temprana ya predice el resultado a coste nulo, cualquier métrica que exija instrumentar el gradiente tiene que demostrar que aporta algo por encima de ella. Este trabajo adopta esa exigencia como criterio central, y por eso TSE reaparece como predictor de referencia en la Sección 2.4.

2.2 Familia de alineación o coherencia direccional

La primera de las dos grandes familias agrupa las métricas que miden en qué medida los gradientes de ejemplos distintos apuntan hacia el mismo sitio. La intuición compartida es que, cuando ejemplos distintos producen gradientes alineados, la red está aprendiendo características comunes a muchos de ellos en lugar de memorizarlos uno a uno, y que esa coherencia se asocia con un aprendizaje más rápido y una mejor generalización.

El marco conceptual de la familia es la hipótesis de gradientes coherentes de Chatterjee [2]. Su punto de partida es una descomposición de la norma del gradiente del minibatch en la energía individual de cada ejemplo más los términos cruzados entre pares: cuando los términos cruzados son positivos, el gradiente agregado se refuerza en las direcciones que muchos ejemplos comparten y se cancela en las idiosincráticas, lo que explicaría por qué el descenso por gradiente estocástico generaliza sin sobreajustar de inmediato. El trabajo es sugerente, pero se queda en lo conceptual: sus medidas operativas exigen partir el conjunto de entrenamiento en ejemplos limpios y corruptos mediante ruido de etiquetas controlado, un montaje que no se traslada a un entrenamiento ordinario.

La versión escalable de esa idea es la m-coherencia de Chatterjee y Zielinski [3]. Reduce la coherencia a un único escalar calculable sobre un minibatch, con una interpretación intuitiva: aproximadamente el número medio de ejemplos que se benefician del paso de descenso obtenido a partir de un ejemplo cualquiera. Los autores observan, entrenando una ResNet-18 sobre ImageNet, que con etiquetas reales la coherencia crece deprisa, mientras que con etiquetas aleatorias también acaba emergiendo, solo que mucho más despacio. De hecho, que la coherencia surja incluso donde no hay estructura que generalizar es el hallazgo que da título al trabajo; lo que separa el aprendizaje de la memorización no es la presencia de coherencia, sino la velocidad con que aparece. La limitación es de cobertura experimental: la evidencia procede de un único conjunto de datos a gran escala, con un tamaño de batch de 4096 y sin aumento de datos, condiciones lejanas a las de un entrenamiento típico, y la métrica se estudia como ventana a la memorización, no como predictor de eficiencia.

La stiffness de Fort et al. [4] mira el mismo fenómeno con el coseno entre gradientes de pares de ejemplos, pero desagregándolo por clases. Su matriz de stiffness por clase revela jerarquías semánticas que la red descubre sola, por ejemplo, que mejorar la clasificación de gatos ayuda más a la de perros que a la de camiones, y los autores documentan que la stiffness intra-clase decae hacia cero justo cuando empieza el sobreajuste, lo que la señala como indicador temprano. El inconveniente práctico es estadístico: el estimador se basa en promedios sobre pares de un probe pequeño, y su variante más informativa exige sondas de cierto tamaño para no quedar dominada por el ruido muestral.

La gradient confusion de Sankararaman et al. [5] adopta el punto de vista del peor caso: mide el coseno más negativo entre cualquier par de gradientes, es decir, cuán antagónicos llegan a ser los ejemplos. Su aportación más citada es relacionar esta cantidad con la arquitectura: la confusión crece con la profundidad pero decrece con la anchura, lo que ofrece una explicación cuantitativa de por qué la sobreparametrización facilita el entrenamiento, y muestra que la normalización por lotes y las conexiones residuales la reducen de forma drástica. Como predictor temprano tiene dos debilidades: al ser un estadístico de extremo (un mínimo) es ruidoso, y su cálculo sobre muchos pares es de los más caros de la familia.

La gradient disparity de Forouzesh y Thiran [6] sustituye el coseno por la distancia entre los gradientes de dos minibatches independientes, derivada de una cota de tipo PAC-Bayes, y la propone como señal de parada temprana. Es de las pocas métricas de la familia con evidencia cuantitativa fuerte: los autores reportan una correlación de Pearson

de 0,957 entre la disparidad medida entre lotes de entrenamiento y la medida entre entrenamiento y validación sobre 220 configuraciones, lo que justifica usar la primera, que no gasta datos de validación, como sustituto de la segunda. Su limitación es de comparabilidad: la métrica depende del tamaño de batch (su varianza decrece con él), de modo que solo es comparable entre entrenamientos que lo fijen.

La propuesta más reciente de la familia es la alineación gradiente-peso (GWA) de Hölzl [7], que mide el coseno entre el gradiente de cada ejemplo y los pesos del clasificador final. Es la métrica con la correlación reportada más alta de todo el corpus: Pearson de 0,99 y Spearman de 0,97 entre su valor máximo a lo largo del entrenamiento y la accuracy de test, y además admite una forma cerrada que la deja casi gratis cuando se calcula solo sobre la última capa. Sus resultados, sin embargo, se obtienen con arquitecturas modernas de tipo convolucional y transformador y con un protocolo orientado a la robustez frente a ruido de etiquetas, por lo que queda abierto si esa correlación tan alta se sostiene en arquitecturas y condiciones distintas.

2.3 Familia de variabilidad estocástica

La segunda familia no mira la dirección relativa de los gradientes, sino su dispersión. La intuición es complementaria de la anterior: un gradiente cuya estimación varía mucho de un minibatch a otro da al optimizador una señal ruidosa, y la magnitud de ese ruido respecto a la señal condiciona cuánto se puede avanzar por paso y cuál es el tamaño de batch a partir del cual deja de merecer la pena agrandarlo.

El trabajo de referencia es el modelo empírico de entrenamiento con lotes grandes de McCandlish et al. [8], que introduce la escala de ruido del gradiente (GNS): el cociente entre la traza de la covarianza del gradiente y el cuadrado de su norma. Su aportación es predecir, antes de barrer el hiperparámetro, el tamaño de batch crítico, esto es, el punto a partir del cual duplicar el batch deja de reducir el número de pasos necesarios. La métrica es, por construcción, una predicción de un hiperparámetro de entrenamiento más que de la eficiencia final, y su versión exacta requiere la Hessiana; la forma simplificada que se usa en la práctica asume que la curvatura es proporcional a la identidad, una aproximación cómoda pero no inocua.

Faghri et al. [9] estudian directamente la varianza del gradiente y proponen una varianza normalizada que la hace comparable entre problemas de distinta escala. Su hallazgo más llamativo es contraintuitivo: en CIFAR e ImageNet la varianza normalizada crece durante el entrenamiento en lugar de decrecer, lo que contradice la imagen ingenua de que el gradiente se va estabilizando a medida que la red aprende. Es un trabajo descriptivo más que predictivo: mide y caracteriza la varianza, pero no la usa para anticipar la eficiencia de un entrenamiento.

Liu et al. [10] cierran la familia con la razón señal-ruido del gradiente por parámetro (GSNR), que es esencialmente el inverso de la varianza normalizada. Su tesis es que un GSNR alto durante el entrenamiento se asocia con un menor hueco de generalización, y la respaldan con un marco teórico que relaciona el GSNR con la mejora de generalización por paso, y con correlaciones de Pearson en el rango de 0,907 a 0,968 entre los dos lados de esa relación. La evidencia, sin embargo, procede en buena parte de entrenamientos con descenso de gradiente puro y tasas de aprendizaje pequeñas, condiciones que aíslan el fenómeno pero se alejan del entrenamiento estocástico habitual.

Conviene situar aquí, como telón de fondo, dos trabajos que no aportan métricas pero justifican el interés por medir la varianza en lugar de combatirla. El gradiente estocástico de varianza reducida de Johnson y Zhang [11] demuestra que reducir explícitamente la

varianza del estimador acelera la convergencia bajo convexidad fuerte, lo que legitima la varianza como cantidad relevante para la velocidad de entrenamiento. Pero Defazio y Bottou [12] muestran, de forma empírica, que esa reducción fracasa en redes profundas modernas: la estructura de suma finita sobre la que se apoya se rompe con la normalización por lotes, el aumento de datos y el dropout, hasta el punto de que el método llega a inyectar más varianza de la que elimina. La conclusión que este trabajo extrae de ese contraste es que, en aprendizaje profundo real, la varianza del gradiente tiene más valor como señal diagnóstica que como objetivo a minimizar.

Por último, los optimizadores que se barren en el estudio enmarcan también esta familia. El repaso de Ruder [13] ofrece la taxonomía de variantes de descenso por gradiente, y Adam [14] y su antecedente RMSProp [15] incorporan en su propia mecánica una razón señal-ruido por parámetro: dividen el gradiente por una estimación de su magnitud reciente, que es justamente lo que mide la familia de variabilidad. Esta coincidencia motiva una decisión de diseño que se justifica en el Capítulo 4: medir todas las métricas sobre el gradiente bruto, y nunca sobre el paso ya preconditionado por el optimizador, para que sean comparables entre SGD y Adam.

2.4 Predictores de referencia sin instrumentar el gradiente

El valor de este trabajo depende de una comparación honesta. Medir el gradiente cuesta, así que el rival no es la métrica más simple ni la que cada artículo proponga, sino el mejor predictor que se puede obtener sin instrumentar el gradiente en absoluto, leyendo solo lo que el entrenamiento ya produce. Ese predictor de referencia tiene dos componentes, ambos de coste prácticamente nulo.

El primero es el estimador de velocidad de entrenamiento (TSE) de la Sección 2.1, que resume la curva de pérdida de entrenamiento temprana. El segundo, y probablemente el más fuerte, es la propia métrica de validación medida en la misma fracción temprana del entrenamiento, es decir, la accuracy o la pérdida de validación a una fracción dada. Es una señal casi gratuita y muy informativa: si las primeras épocas ya separan las configuraciones buenas de las malas en validación, una métrica de gradiente que no supere esa separación no añade nada que merezca su coste.

Estos dos predictores definen el suelo que las métricas de gradiente deben superar. La comparación no se hace solo en términos de correlación cruda, sino de valor incremental: cuánto añade una métrica una vez descontado lo que la curva de pérdida y la validación temprana ya predicen. Este es el contraste que el objetivo 2 del Capítulo 1 señala como decisivo, y su formalización se detalla en el Capítulo 4.

2.5 Posicionamiento de este trabajo

La revisión anterior deja ver un patrón. Cada métrica se ha propuesto y validado por separado, con un objetivo propio (explicar la generalización, elegir el tamaño de batch o decidir cuándo parar), sobre un conjunto de datos y una arquitectura concretos, y rara vez frente al predictor de referencia barato. La Tabla 2.1 resume las métricas revisadas en los mismos ejes, lo que hace visible esa dispersión: conviven señales de signo y coste muy distintos, evaluadas en bancos de prueba que no se solapan.

De ese patrón se desprende el hueco que este trabajo ocupa. Hasta donde sabemos, ningún trabajo previo compara las dos familias sobre un mismo banco de pruebas, barre la fracción temprana del entrenamiento para establecer cuán pronto basta medir, comprueba la robustez de la relación al cambiar de arquitectura, de conjunto de datos y de

Tabla 2.1: Las métricas tempranas revisadas, situadas en ejes comunes. El coste es relativo al de un paso de entrenamiento. La señal indica el sentido que cada trabajo asocia con un entrenamiento más eficiente o una mejor generalización.

Métrica	Familia	Señal asociada	Coste
m-coherencia [3]	Alineación	alta es mejor	medio
Stiffness [4]	Alineación	alta es mejor	medio
Gradient confusion [5]	Alineación	baja es mejor	alto
Gradient disparity [6]	Alineación	baja es mejor	bajo
GWA [7]	Alineación	alta es mejor	bajo
Varianza normalizada [9]	Variabilidad	baja es mejor	bajo
Escala de ruido GNS [8]	Variabilidad	baja es mejor	medio
GSNR [10]	Variabilidad	alta es mejor	medio
TSE (referencia) [1]	—	baja es mejor	nulo

optimizador, y, sobre todo, exige a cada métrica superar al predictor de referencia barato antes de darla por útil. La Tabla 2.2 resume esta comparación de cobertura.

Tabla 2.2: Cobertura de este trabajo frente a trabajos representativos del estado del arte, en los ejes que definen la aportación.

Trabajo	Multi-familia	Barrido temporal	Robustez cross-setting	Control por baseline	Pareto coste-potencia
Ru et al. [1]	No	Parcial	Parcial	—	No
Forouzesh y Thiran [6]	No	Parcial	Parcial	No	No
Hölzl [7]	No	Parcial	Parcial	Parcial	No
McCandlish et al. [8]	No	No	Parcial	No	No
Este trabajo	Sí	Sí	Sí	Sí	Sí

La aportación no es, por tanto, una métrica nueva, sino una evaluación comparativa y rigurosa de las existentes. El resultado que se busca no es coronar a la que mejor predice, sino a la que mejor predice por unidad de coste, lo que se expresa como un frente de Pareto entre potencia predictiva y coste de cómputo. Conviene acotar también lo que el trabajo no puede afirmar: la evidencia se limita a la clasificación de imágenes, con ImageNet sustituido por su versión reducida, y es de naturaleza correlacional, de modo que las relaciones que se encuentren no autorizan conclusiones causales ni una extrapolación automática a otros dominios. El Capítulo 4 traduce este posicionamiento en un diseño experimental con hipótesis falsables.

CAPÍTULO 3

Fundamentos teóricos

Este capítulo fija las definiciones formales que el Capítulo 2 maneja en su versión conceptual. Primero se establece la notación común, desde el descenso por gradiente estocástico hasta la geometría de los gradientes por ejemplo (Secciones 3.1 y 3.2). Sobre esa base se definen las dos familias de métricas, la de alineación y la de variabilidad (Secciones 3.3 y 3.4). La Sección 3.5 define los indicadores de eficiencia que actúan como variables a predecir. Aquí solo se definen los objetos; el protocolo de medición (el *probe*, las ventanas, el suavizado) y las hipótesis con signo asociadas a cada métrica se detallan en el Capítulo 4.

3.1 Descenso por gradiente estocástico

Sea un conjunto de entrenamiento de n ejemplos $\{(x_i, y_i)\}_{i=1}^n$, una red f_θ con parámetros $\theta \in \mathbb{R}^P$ y una función de pérdida por ejemplo $\ell_i(\theta) = \ell(f_\theta(x_i), y_i)$. El objetivo del entrenamiento es minimizar el riesgo empírico $f(\theta) = \frac{1}{n} \sum_{i=1}^n \ell_i(\theta)$. El descenso por gradiente estocástico con minibatch no evalúa el gradiente exacto $\nabla f(\theta)$, sino una estimación sobre un subconjunto S_t de B ejemplos extraídos al azar en cada paso:

$$\theta_{t+1} = \theta_t - \eta_t \hat{g}_t, \quad \hat{g}_t = \frac{1}{B} \sum_{i \in S_t} \nabla_\theta \ell_i(\theta_t), \quad (3.1)$$

donde η_t es la tasa de aprendizaje. Cuando los ejemplos se muestrean de forma independiente, el estimador es *insesgado*, $\mathbb{E}[\hat{g}_t] = \nabla f(\theta_t)$, lo que garantiza que SGD optimiza la pérdida correcta y no una distorsión sistemática de ella. Su dispersión, en cambio, no es nula: para ejemplos i.i.d.

$$\text{Var}[\hat{g}_t] = \frac{1}{B} \text{tr}(\Sigma), \quad \Sigma = \text{Cov}_i[\nabla_\theta \ell_i(\theta_t)], \quad (3.2)$$

con Σ la covarianza del gradiente por ejemplo. Esta varianza escala como $1/B$ pero persiste incluso en el óptimo, donde $\nabla f = 0$ y aun así $\text{Var}[\hat{g}] > 0$, porque cada minibatch apunta a un objetivo ligeramente distinto. Es el suelo de ruido que obliga a decaer la tasa de aprendizaje para converger en lugar de orbitar el mínimo, y es la cantidad que cuantifica la familia de variabilidad.

Dos resúmenes estadísticos del gradiente por ejemplo vertebran el resto del capítulo. El *primer momento* $\mathbb{E}[g]$ describe la dirección consistente del gradiente y es lo que estiman el momento y la media móvil m_t de Adam [14]. El *segundo momento*, a través de $\mathbb{E}[\|g\|^2]$ o de la traza de Σ , describe su magnitud y su dispersión, y es lo que recogen el segundo

momento v_t de Adam y la escala de ruido del gradiente. Las dos familias de métricas leen, respectivamente, la dirección relativa de los gradientes por ejemplo (alineación) y su dispersión (variabilidad). Para que ambas sean comparables entre SGD y Adam, todas se calculan sobre el gradiente bruto $\nabla \ell$ y nunca sobre el paso ya precondicionado por el optimizador, decisión que el Capítulo 2 justifica y que el Capítulo 4 retoma.

3.2 Geometría del gradiente

El objeto sobre el que se construyen casi todas las métricas es el gradiente por ejemplo

$$g_i = \nabla_{\theta} \ell(f_{\theta}(x_i), y_i) \in \mathbb{R}^P, \quad (3.3)$$

el gradiente de la pérdida de un único ejemplo, antes de promediar. El gradiente del minibatch es su media $\hat{g} = \frac{1}{B} \sum_i g_i$, pero esa media descarta la estructura estadística que las métricas explotan: la distribución de los g_i (su covarianza, su curtosis) describe el ruido, y sus productos internos por pares describen si los ejemplos cooperan o se cancelan. Para medirlos sin contaminar la dinámica de entrenamiento, las métricas se evalúan sobre un *probe* fijo de M ejemplos, muestreado una sola vez y reutilizado en cada medición, de modo que la variación temporal de la métrica refleje cambios reales en el modelo y no el remuestreo.

Las dos operaciones elementales son la matriz de Gram y la similitud coseno. La matriz de Gram recoge todos los productos internos por pares, $\mathbf{G}_{ij} = \langle g_i, g_j \rangle$, y la similitud coseno los normaliza por magnitud:

$$\cos(g_i, g_j) = \frac{\langle g_i, g_j \rangle}{\|g_i\| \|g_j\|} \in [-1, 1]. \quad (3.4)$$

El coseno vale 1 si los dos gradientes apuntan en la misma dirección, 0 si son ortogonales y -1 si son opuestos. La normalización por norma importa porque lo relevante para la cooperación entre ejemplos es la dirección relativa, no la escala individual de cada gradiente. Conviene además recordar un hecho de alta dimensión: dos vectores isótropos aleatorios en $\mathbb{R}^P$ tienen un coseno típico del orden de $1/\sqrt{P}$, prácticamente cero cuando P es del orden de millones. Por tanto, cualquier desviación sistemática positiva del coseno medio entre gradientes por ejemplo es señal real y no fluctuación muestral.

3.3 Métricas de alineación

La familia de alineación cuantifica en qué medida los gradientes de ejemplos distintos apuntan hacia el mismo sitio. Su marco conceptual es la descomposición de la norma del gradiente del minibatch [2],

$$\left\| \sum_i g_i \right\|^2 = \sum_i \|g_i\|^2 + \sum_{i \neq j} \langle g_i, g_j \rangle, \quad (3.5)$$

donde el primer término es la energía individual de cada ejemplo y el segundo, la suma de productos internos cruzados, es donde vive la coherencia. Las métricas siguientes son distintos agregadores de ese término cruzado.

m-coherencia. Reduce la coherencia a un único escalar sobre el probe de M ejemplos [3]:

$$\alpha = \frac{\left\| \sum_{i=1}^M g_i \right\|^2}{\sum_{i=1}^M \|g_i\|^2} \in [0, M]. \quad (3.6)$$

Vale M cuando los gradientes son idénticos y 1 en el *límite ortogonal*, donde son mutuamente perpendiculares y de misma norma; valores por debajo de 1 indican gradientes anticorrelados. Su lectura intuitiva es el número medio de ejemplos que se benefician de un paso de descenso obtenido a partir del gradiente de un ejemplo cualquiera. Una alineación mayor se asocia con un aprendizaje más coherente, de modo que se predice α alta como señal de entrenamiento eficiente.

Stiffness. Mide el coseno entre gradientes de pares de ejemplos, desagregado por clases [4]. Sobre el probe se definen una variante de coseno y una de signo,

$$S_{\cos} = \mathbb{E}_{i \neq j} [\cos(g_i, g_j)], \quad S_{\text{sign}} = \mathbb{E}_{i \neq j} [\text{sign} \langle g_i, g_j \rangle], \quad (3.7)$$

cada una restringida a pares de la misma clase ($y_i = y_j$, *stiffness intra-clase*) o de clases distintas ($y_i \neq y_j$, *inter-clase*). Una *stiffness* intra-clase alta indica que la red ha aprendido características compartidas y que cada paso de gradiente sobre un ejemplo beneficia al resto de su clase; el indicador robusto es la diferencia intra-clase menos inter-clase. La señal predictiva es más fuerte en la fase temprana, porque la *stiffness* decae hacia cero cuando comienza el sobreajuste.

Gradient confusion. Adopta el punto de vista del peor caso: el coseno más negativo entre cualquier par de gradientes del probe [5]. En su forma normalizada,

$$\hat{\eta} = - \min_{i \neq j} \cos(g_i, g_j). \quad (3.8)$$

Un $\hat{\eta}$ alto señala que existe al menos un par de ejemplos cuyos gradientes se oponen con fuerza, lo que frena el avance neto de SGD; un $\hat{\eta}$ cercano a cero indica gradientes que no se contradicen. Por ser un estadístico de extremo es ruidoso, así que junto al mínimo se reporta la masa de la distribución de cosenos. Se predice que una confusión menor acompaña a un entrenamiento más rápido.

Gradient disparity. Sustituye el coseno por la distancia entre los gradientes de dos minibatches independientes, derivada de una cota de tipo PAC-Bayes [6]. Para s submuestras del probe,

$$\overline{\mathcal{D}} = \binom{s}{2}^{-1} \sum_{i < j} \|g_i - g_j\|_2. \quad (3.9)$$

Es una magnitud ℓ_2 sin normalizar, no una similitud coseno: la cota teórica del trabajo depende de $\|g_i - g_j\|_2^2$, de modo que dividir por la norma rompería la conexión y no se hace. Una disparidad baja indica minibatches coherentes, y se predice como señal de eficiencia, con la salvedad de que su magnitud depende del tamaño de batch y solo es comparable entre entrenamientos que lo fijen.

Alineación gradiente-peso (GWA). Mide el coseno entre el gradiente por ejemplo y los pesos del clasificador final, restringido a la última capa lineal [7]. Para cada ejemplo del probe, $\gamma_i = \cos(g_i^{(\text{últ.})}, w^{(\text{últ.})})$, y el agregado por época corrige la media por el exceso de curtosis de la distribución de puntuaciones:

$$\text{GWA} = \frac{\bar{\gamma}}{\frac{\mu_4}{\mu_2^2} - 3 + \beta}, \quad \beta = 1, 2, \quad (3.10)$$

donde $\bar{\gamma}$ es la media de las γ_i , μ_2 y μ_4 sus momentos centrales de segundo y cuarto orden, y $\mu_4/\mu_2^2 - 3$ el exceso de curtosis (nulo para una gaussiana). El denominador descuenta las distribuciones de cola pesada, donde pocas muestras dominan la media. El trabajo de origen define el gradiente como $-\nabla \ell$; al medirse sobre el gradiente bruto $\nabla \ell$ el signo se invierte, lo que se documenta en el análisis. Una GWA alta se asocia con mejor generalización.

Cada una de estas definiciones lleva implícita una predicción direccional: más coherencia, más stiffness intra-clase, menos confusión, menos disparidad o más alineación gradiente-peso deberían acompañar a un entrenamiento más eficiente. Esas predicciones con signo se formalizan como hipótesis falsable en el Capítulo 4.

3.4 Métricas de variabilidad

La familia de variabilidad no mira la dirección relativa de los gradientes, sino su dispersión respecto a la señal. Sus tres métricas son facetas de una misma razón señal-ruido del gradiente.

Varianza normalizada (NGV). Hace comparable la varianza del gradiente entre problemas de distinta escala dividiéndola por la magnitud de la señal [9]. Estimada sobre K sub-batches independientes del probe,

$$\text{NGV} = \frac{\text{tr}(\text{Cov}(g))}{\|\mathbb{E}[g]\|^2}. \quad (3.11)$$

Es el inverso de una razón señal-ruido: por debajo de 1 la señal del gradiente medio domina sobre el ruido, por encima domina el ruido. Esta forma, de tipo traza sobre norma, es una adaptación deliberada de la versión literal del trabajo de origen ($\mathbb{V}[g_j]/\mathbb{E}[g_j^2]$ por coordenada), monótonamente equivalente. Una NGV menor indica menos ruido relativo, si bien empíricamente la métrica crece durante el entrenamiento en lugar de decrecer.

Escala de ruido del gradiente (GNS). Predice, antes de barrer el hiperparámetro, el tamaño de batch crítico a partir del cual ampliar el batch deja de reducir el número de pasos [8]. Su forma simplificada es

$$\mathcal{B}_{\text{simple}} = \frac{\text{tr}(\Sigma)}{\|G\|^2}, \quad (3.12)$$

con Σ la covarianza por ejemplo y G el gradiente medio. La versión exacta $\mathcal{B}_{\text{noise}} = \text{tr}(H\Sigma)/(G^\top HG)$ requiere la Hessiana H y se descarta por coste; la simplificada asume $H \propto I$. Por construcción, $\mathcal{B}_{\text{simple}} \approx B \cdot \text{NGV}$, relación exacta en esperanza que emparenta esta métrica con la NGV.

Razón señal-ruido por parámetro (GSNR). Lleva la razón señal-ruido al nivel de cada parámetro θ_j [10]:

$$r(\theta_j) = \frac{\tilde{g}(\theta_j)^2}{\rho^2(\theta_j)}, \quad \tilde{g}(\theta_j) = \mathbb{E}_i[g_{i,j}], \quad \rho^2(\theta_j) = \text{Var}_i[g_{i,j}], \quad (3.13)$$

agregado por la media sobre los parámetros, nunca por la suma, que sería incomparable entre arquitecturas de distinto tamaño. Es esencialmente el recíproco por parámetro de la NGV: un GSNR alto significa que la media del gradiente por ejemplo domina a su varianza, y se asocia con un hueco de generalización pequeño. Las tres métricas miden, pues, la misma razón señal-ruido desde ángulos distintos, lo que las hace parcialmente redundantes; esa redundancia se contrasta empíricamente, como recoge el Capítulo 4.

3.5 Indicadores de eficiencia del entrenamiento

Las métricas anteriores son las variables predictoras; las que siguen son las variables a predecir, esto es, lo que en este trabajo se entiende por eficiencia del entrenamiento. Se leen sobre la curva de monitorización de validación a lo largo del presupuesto de épocas T . El protocolo concreto, incluido el suavizado de la curva, la separación entrenamiento/validación/test y el tratamiento del censurado en el análisis, se especifica en el Capítulo 4.

Épocas hasta el umbral (indicador primario). El número de épocas que tarda la precisión de validación en alcanzar un nivel objetivo τ propio de cada conjunto de datos,

$$t^* = \min\{t \leq T : \text{acc}_{\text{val}}(t) \geq \tau\}. \quad (3.14)$$

Si la precisión no cruza el umbral dentro del presupuesto, el valor queda *censurado*: no se descarta, sino que se trata como el peor resultado posible, porque los extremos de la rejilla de tasas de aprendizaje no llegan al umbral por diseño. Un t^* menor indica un entrenamiento más rápido.

AUC de la pérdida de validación. El área bajo la curva de pérdida de validación dentro del presupuesto, aproximada por la regla trapezoidal sobre el eje de épocas. Resume toda la trayectoria en un escalar: cuanto menor es el área, más rápido descende la pérdida.

Mejor pérdida de validación. El mínimo de la pérdida de validación alcanzado dentro del presupuesto, que mide el mejor rendimiento intermedio con independencia de la velocidad con que se alcanza.

Rendimiento final. La precisión sobre el conjunto de test, evaluada una única vez al terminar el entrenamiento. Es la variable objetivo certificada, separada de la curva de validación que se monitoriza durante el entrenamiento.

Gap de generalización. La diferencia entre el rendimiento en test y en entrenamiento al final del run, medida sobre un subconjunto fijo del conjunto de entrenamiento del mismo tamaño que el de test. En términos de pérdida y de precisión,

$$\text{gap}_{\text{loss}} = \mathcal{L}_{\text{test}} - \mathcal{L}_{\text{train}}, \quad \text{gap}_{\text{acc}} = \text{acc}_{\text{train}} - \text{acc}_{\text{test}}, \quad (3.15)$$

donde un valor positivo indica sobreajuste. Es la variable objetivo de generalización frente a la que se contrastan, en particular, las métricas que sus trabajos de origen vinculan al hueco de generalización.

CAPÍTULO 4

Metodología y diseño experimental

4.1 Hipótesis

4.2 Variables

4.2.1. Dependientes: eficiencia del entrenamiento

4.2.2. Independientes: métricas tempranas

4.3 Ventana temporal

4.4 Setup de entrenamiento

El estudio emplea cuatro conjuntos de clasificación de imágenes de dificultad creciente: MNIST [16], CIFAR-10 y CIFAR-100 [17] y Tiny-ImageNet [18]. En todos ellos el conjunto de prueba oficial se mantiene intacto y el de validación se recorta del entrenamiento oficial mediante muestreo estratificado por clase con una semilla fija; en CIFAR esto reproduce el split 45k/5k de He et al. [19]. Así la validación conserva las proporciones de clase del entrenamiento y la partición es idéntica en los más de novecientos entrenamientos. La Tabla 4.1 recoge los tamaños resultantes, el número de clases y la dimensión de entrada de cada conjunto.

Tabla 4.1: Conjuntos de datos y particiones. El conjunto de validación se obtiene del entrenamiento oficial por muestreo estratificado por clase con semilla fija; el de prueba es el oficial. En Tiny-ImageNet el conjunto de validación público hace de prueba, porque las etiquetas del de prueba oficial no son públicas; por eso el total usable es de 110.000 ejemplos y no de 120.000.

Conjunto	Total	Entren.	Valid.	Prueba	Clases	Dimensión
MNIST	70.000	50.000	10.000	10.000	10	$1 \times 28 \times 28$
CIFAR-10	60.000	45.000	5.000	10.000	10	$3 \times 32 \times 32$
CIFAR-100	60.000	45.000	5.000	10.000	100	$3 \times 32 \times 32$
Tiny-ImageNet	110.000	90.000	10.000	10.000	200	$3 \times 64 \times 64$

La Tabla 4.1 fija el tamaño del problema; conviene además situar qué exactitud cabe esperar de cada arquitectura en estas condiciones. La comparación honesta no se hace contra el estado del arte, que casi siempre usa aumento de datos, weight decay y entrenamientos largos, sino contra el *régimen comparable*: redes entrenadas desde cero, sin aumento de datos y a resolución nativa, que es el de este estudio. La Tabla 4.2 reúne ese

régimen para las tres arquitecturas, con cifras tomadas de filas de ablación o de baseline de la literatura: para el MLP, Bachmann et al. [20]; para la CNN pequeña, Chen y Ho [21] (cota superior, con activación GReLU) y Mantzaris [22] (cota inferior, con BatchNorm); y para ResNet-18, las filas sin aumento de Ye et al. [23] y Ko et al. [24], con Larsson et al. [25] como corroboración en CIFAR-100. En MNIST cualquier red pequeña satura en torno al 99 % (LeCun et al. [16]).

Tabla 4.2: Exactitud de test de referencia por arquitectura en el *régimen comparable* (desde cero, sin aumento de datos, resolución nativa), que es el de este estudio. Son bandas esperadas, no objetivos: las fuentes suelen entrenar más tiempo o con redes algo mayores, de modo que acotan por arriba. Las celdas con † no tienen baseline publicado en este régimen (CNN simple y ResNet-18 desde cero, sin aumento, a 64×64 nativo en Tiny-ImageNet); son estimaciones y un punto de datos novedoso del estudio.

Arquitectura	MNIST	CIFAR-10	CIFAR-100	Tiny-ImageNet
FC (MLP 1024-1024)	~98,4 %	~50–54 %	~25–29 %	~8–12 %
CNN (3 bloques)	~99,0–99,4 %	~70–80 %	~45–55 %	~20–35 % †
ResNet-18 (stem 3×3)	~99,0–99,5 %	~84–92 %	~50–57 %	~40–50 % †

Como cota laxa de contexto, ResNet-18 entrenada desde cero a resolución nativa pero con aumento de datos alcanza 94,55 % (CIFAR-10), 78,07 % (CIFAR-100) y 50,68 % (Tiny-ImageNet) según GenURL [26]; la distancia con la Tabla 4.2 es justo lo que aportan el aumento de datos, el weight decay y los entrenamientos largos. Para el MLP y la CNN, los mejores resultados publicados exigen cambiar de clase de arquitectura (redes densas que aprenden conectividad local tipo convolución, Neyshabur [27]; redes totalmente convolucionales profundas, Springenberg et al. [28]), de modo que no son techos comparables del MLP llano ni de la CNN simple.

4.5 Matriz de experimentos

4.6 Protocolo de evaluación

4.7 Protocolo de análisis

4.8 Amenazas a la validez

CAPÍTULO 5

Implementación

5.1 Arquitectura del pipeline

5.2 Cálculo de las métricas

5.3 Reproducibilidad

5.4 Ejecución y reanudación en cluster

5.5 Pilot de calibración

CAPÍTULO 6

Resultados

6.1 Calibración del pilot

6.2 Correlaciones por condición

6.3 Análisis agregado y barrido temporal

6.4 Valor incremental sobre el baseline

6.5 Qué familia predice mejor

6.6 Robustez cross-optimizador

6.7 Frente de Pareto: potencia predictiva vs coste

6.8 Coherencia con el mecanismo declarado

CAPÍTULO 7

Conclusiones

7.1 Cumplimiento de objetivos

7.2 Aportaciones

7.3 Limitaciones

7.4 Trabajo futuro

Bibliografía

- [1] Robin Ru et al. "Speedy Performance Estimation for Neural Architecture Search". En: *Advances in Neural Information Processing Systems*. Vol. 34. 2021.
- [2] Satrajit Chatterjee. "Coherent Gradients: An Approach to Understanding Generalization in Gradient Descent-based Optimization". En: *International Conference on Learning Representations (ICLR)*. 2020. arXiv: [2002.10657](#).
- [3] Satrajit Chatterjee y Piotr Zielinski. *Making Coherence Out of Nothing At All: Measuring the Evolution of Gradient Alignment*. 2020. arXiv: [2008.01217](#).
- [4] Stanislav Fort et al. *Stiffness: A New Perspective on Generalization in Neural Networks*. 2019. arXiv: [1901.09491](#).
- [5] Karthik Abinav Sankararaman et al. "The Impact of Neural Network Overparameterization on Gradient Confusion and Stochastic Gradient Descent". En: *Proceedings of the 37th International Conference on Machine Learning (ICML)*. Vol. 119. Proceedings of Machine Learning Research. PMLR, 2020.
- [6] Mahsa Forouzesh y Patrick Thiran. "Disparity Between Batches as a Signal for Early Stopping". En: *Machine Learning and Knowledge Discovery in Databases. Research Track (ECML PKDD 2021)*. Springer, 2021. DOI: [10.1007/978-3-030-86520-7_14](#).
- [7] Florian A. Hözl, Daniel Rueckert y Georgios Kaissis. "Gradient-Weight Alignment as a Train-Time Proxy for Generalization in Classification Tasks". En: *Advances in Neural Information Processing Systems*. Vol. 38. 2025. arXiv: [2510.25480](#).
- [8] Sam McCandlish et al. *An Empirical Model of Large-Batch Training*. 2018. arXiv: [1812.06162](#).
- [9] Fartash Faghri et al. *A Study of Gradient Variance in Deep Learning*. 2020. arXiv: [2007.04532](#).
- [10] Jinlong Liu et al. "Understanding Why Neural Networks Generalize Well Through GSNR of Parameters". En: *International Conference on Learning Representations (ICLR)*. 2020. arXiv: [2001.07384](#).
- [11] Rie Johnson y Tong Zhang. "Accelerating Stochastic Gradient Descent using Predictive Variance Reduction". En: *Advances in Neural Information Processing Systems*. Vol. 26. 2013.
- [12] Aaron Defazio y Léon Bottou. "On the Ineffectiveness of Variance Reduced Optimization for Deep Learning". En: *Advances in Neural Information Processing Systems*. Vol. 32. 2019.
- [13] Sebastian Ruder. *An Overview of Gradient Descent Optimization Algorithms*. 2016. arXiv: [1609.04747](#).

- [14] Diederik P. Kingma y Jimmy Ba. “Adam: A Method for Stochastic Optimization”. En: *3rd International Conference on Learning Representations (ICLR)*. 2015. arXiv: [1412.6980](#).
- [15] Tijmen Tieleman y Geoffrey Hinton. *Lecture 6.5—RMSProp: Divide the Gradient by a Running Average of Its Recent Magnitude*. COURSE: Neural Networks for Machine Learning. 2012.
- [16] Yann LeCun et al. “Gradient-Based Learning Applied to Document Recognition”. En: *Proceedings of the IEEE* 86.11 (1998), págs. 2278-2324. DOI: [10.1109/5.726791](#).
- [17] Alex Krizhevsky. *Learning Multiple Layers of Features from Tiny Images*. Inf. téc. University of Toronto, 2009.
- [18] Ya Le y Xuan Yang. *Tiny ImageNet Visual Recognition Challenge*. Inf. téc. CS231N course report. Stanford University, 2015.
- [19] Kaiming He et al. “Deep Residual Learning for Image Recognition”. En: *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2016. arXiv: [1512.03385](#).
- [20] Gregor Bachmann, Sotiris Anagnostidis y Thomas Hofmann. “Scaling MLPs: A Tale of Inductive Bias”. En: *Advances in Neural Information Processing Systems*. Vol. 36. 2023. arXiv: [2306.13575](#).
- [21] Z. Chen y P.-H. Ho. *Deep Global-Connected Net with the Generalized Multi-Piecewise ReLU Activation in Deep Learning*. 2018. arXiv: [1807.03116](#).
- [22] A. V. Mantzaris. *Exploring the Hierarchical Reasoning Model for Small Natural-Image Classification Without Augmentation*. 2025. arXiv: [2510.03598](#).
- [23] X. Ye et al. *ZeroPur: Succinct Training-Free Adversarial Purification*. 2024. arXiv: [2406.03143](#).
- [24] G. Ko, H. Kim y J. Lee. “Learning Infinitesimal Generators of Continuous Symmetries from Data”. En: *Advances in Neural Information Processing Systems*. Vol. 37. 2024. arXiv: [2410.21853](#).
- [25] Gustav Larsson, Michael Maire y Gregory Shakhnarovich. “FractalNet: Ultra-Deep Neural Networks Without Residuals”. En: *International Conference on Learning Representations (ICLR)*. 2017. arXiv: [1605.07648](#).
- [26] Siyuan Li et al. “GenURL: A General Framework for Unsupervised Representation Learning”. En: *IEEE Transactions on Neural Networks and Learning Systems* (2023). DOI: [10.1109/TNNLS.2023.3332087](#). arXiv: [2110.14553](#).
- [27] Behnam Neyshabur. “Towards Learning Convolutions from Scratch”. En: *Advances in Neural Information Processing Systems*. Vol. 33. 2020. arXiv: [2007.13657](#).
- [28] Jost Tobias Springenberg et al. *Striving for Simplicity: The All Convolutional Net*. ICLR 2015 Workshop Track. 2015. arXiv: [1412.6806](#).

APÉNDICE A

Objetivos de Desarrollo Sostenible

APÉNDICE B

Configuración del sistema y reproducibilidad

B.1 Entorno software

B.2 Hardware y ejecución

B.3 Reproducibilidad determinista
